

Rilevamento Automatico di Inversioni degli Elettrodi ECG mediante Deep Learning

1. Introduzione e Obiettivo

L'obiettivo del progetto è sviluppare un sistema di rilevamento automatico delle inversioni degli elettrodi periferici in registrazioni ECG a 12 derivazioni. Il sistema utilizza una rete neurale convoluzionale (LDenseNet) addestrata su dati *sintetici* (inversioni simulate matematicamente a partire da ECG reali normali) e successivamente raffinata tramite *fine-tuning* su un piccolo dataset di ECG reali con inversioni cliniche confermate da un cardiologo.

Classi di inversione rilevate

Classe	Codice	Descrizione	I'	II'	III'	aVR'	aVL'	aVF'
0	Normale	Nessuna inversione	I	II	III	aVR	aVL	aVF
1	LA-RA	Scambio LA ↔ RA	$-I$	III	II	aVL	aVR	aVF
2	RA-LL	Scambio RA ↔ LL	$-III$	$-II$	$-I$	aVF	aVL	aVR
3	LA-LL	Scambio LA ↔ LL	II	I	$-III$	aVR	aVF	aVL
4	ROT_ORA	Rotazione RA→LA→LL→RA	III	$-I$	$-II$	aVL	aVF	aVR
5	ROT_ANT	Rotazione RA→LL→LA→RA	$-II$	$-III$	I	aVF	aVR	aVL

Classi scartate dalla SQA (coinvolgono RL, elettrodo di ground):

Classe	Codice	I'	II'	III'	Augmented leads
6	RL-RA	II	III	$III - II$	$aVR' = -\frac{I'+II'}{2}, aVL' = I' - \frac{II'}{2}, aVF' = II' - \frac{I'}{2}$
7	RL-LA	$III - II$	II	$II - (III - II)$	idem sopra

[!NOTE] Le classi 6 e 7 producono segnali quasi piatti su almeno una derivazione periferica (il cavo RL è il ground dell'elettrocardiografo e non registra attività cardiaca propria). Vengono rilevate e scartate automaticamente dal modulo SQA prima dell'inferenza.

2. Pipeline Dati e Struttura del Database

2.1 Sorgente e Struttura del Database Clinico

I segnali ECG provengono da un database relazionale SQLite (records_complete.db) contenente registrazioni reali a 12 derivazioni.

Schema dettagliato della tabella records:

- *id* (*INTEGER* - *Intero*): Identificativo numerico univoco del tracciato (mappato biunivocamente sul file fisico in formato grezzo **EDF - European Data Format**, uno standard aperto internazionale per la memorizzazione di segnali biologici e fisiologici).
- *status* (*TEXT* - *Testo*): Stato di refertabilità clinica assegnato dai cardiologi (utilizzato come etichetta gold standard di qualità):
 - 'reported': Segnale validato dal medico, refertato e clinicamente interpretabile (esente da disturbi invalidanti).
 - 'rejected': Esame scartato dal cardiologo a causa di scarsa qualità tecnica o artefatti fisici estremi.
- *report* (*BLOB/TEXT* - *Oggetto binario/Testo JSON*): Stringa strutturata in formato JSON (JavaScript Object Notation) contenente le misurazioni prodotte dall'apparecchio elettrocardiografo:
 - *measurements*: Parametri cardiaci calcolati:
 - *HR* (*Heart Rate*): Frequenza cardiaca media espressa in bpm (battiti al minuto).
 - *PQ*: Intervallo temporale tra l'inizio dell'onda P (depolarizzazione atriale) e l'inizio del complesso QRS (depolarizzazione ventricolare), espresso in secondi.
 - *QRS*: Durata complessiva del picco principale di depolarizzazione ventricolare (complesso QRS), espressa in secondi.
 - *QT*: Intervallo tra l'inizio della depolarizzazione ventricolare (QRS) e la fine della ripolarizzazione ventricolare (onda T).
 - *QTc*: Intervallo QT corretto rispetto alla frequenza cardiaca tramite la **formula di BAZETT** ($QTc = \frac{QT}{\sqrt{RR}}$ dove *RR* è l'intervallo R-R espresso in secondi), necessaria per standardizzare la diagnosi a frequenze cardiache variabili.
 - *adjustments*: Impostazioni fisiche dei filtri attivi sull'elettrocardiografo (filters) identificati da codici numerici standard.
 - *codified*: Codici alfanumerici standardizzati associati ai singoli referti cardiologici per l'archiviazione automatizzata.
- *text* (*TEXT* - *Testo*): Referto descrittivo definitivo in chiaro redatto dal cardiologo.

Esempio concreto di record (*id*: 668833):

- *Stato*: 'reported'
- *Metadati clinici (report JSON parsed)*:

```
{
  "measurements": {
    "HR": [{"average": 64}, "bpm"],
    "PQ": [{"average": 0.14}, "s"],
    "QRS": [{"average": 0.08}, "s"],
    "QT": [{"average": 0.36}, "s"],
    "QTc": [{"average": 0.372}, "s"]
  },
  "adjustments": {
    "timeOffset": 0,
    "filters": [{"id": "4"}, {"id": "5"}]
  },
  "codified": [
    {"type": "code", "value": "BTWSCR01"},
  ]
}
```

```

    {"type": "code", "value": "BTWSCA01"},
    {"type": "code", "value": "BTWSCE04"},
    {"type": "code", "value": "BTWSCQ01"}
  ]
}

```

- *Referto in chiaro (text):* "Ritmo sinusale. Asse intermedio. Non segni elettrici di preciso significato patologico. ECG nei limiti della norma."

Per lo studio e la validazione delle inversioni reali, viene impiegato un subset clinico reale bilanciato di 466 *record clinici reali* (thesis-sample.csv), la cui distribuzione riflette la frequenza epidemiologica degli errori in corsia:

Classe	Descrizione Inversione	Record Clinici Reali
0	Normale (Nessuno scambio)	202
1	LA-RA (Limb Swap standard)	194
2	RA-LL	15
3	LA-LL	14
4	ROT_ORA (Rotazione Oraria)	7
5	ROT_ANT (Rotazione Antioraria)	34

2.2 Preprocessing del Segnale ed Elaborazione Spettrale

Il tracciato originale registrato ad alta risoluzione (1000 Hz) viene condizionato da una catena deterministica di filtri digitali su ogni singola derivazione:

1. Filtrazione Notch a 50 Hz (Rimozione Rumore di Rete):

- *Configurazione:* Filtro Notch di tipo **IIR (Infinite Impulse Response - Risposta all'impulso infinita)** a banda strettissima progettato tramite `scipy.signal.iirnotch`.
- *Fattore di Merito $Q = 30$ (Quality Factor):* Parametro adimensionale che esprime la selettività del filtro, definito come il rapporto tra la frequenza centrale (50 Hz) e la larghezza di banda a -3 dB. Con $Q = 30$, la banda rimossa è estremamente ridotta, pari a circa 1.67 Hz ($50/30 = 1.67$ Hz), azzerando il disturbo elettrico senza intaccare i potenziali fisiologici circostanti.
- *Fase Zero (filtfilt):* Esecuzione del filtro Notch in modalità bidirezionale (in avanti e all'indietro nel tempo), che annulla matematicamente lo sfasamento temporale indotto per preservare l'allineamento dei picchi del segnale.
- *Mitigazione del Ringing:* Il *ringing* è una distorsione fisica oscillatoria transitoria introdotta dai filtri IIR selettivi in presenza di repentine discontinuità (gradini di tensione). Tale fenomeno viene prevenuto scartando a monte i gradini maggiori di `adc_step_limit` (\$2000, \mu\$V - microvolt) prima che eccitino il filtro.

2. Filtrazione Passa-Banda (0.5 – 120 Hz):

- *Configurazione*: Filtro Butterworth di 4° ordine implementato in **Second-Order Sections (SOS - Sezioni del Secondo Ordine)**. La scomposizione in SOS (coppie di filtri di secondo ordine in cascata) garantisce una stabilità numerica ottimale contro errori di quantizzazione a virgola mobile.
- *Filtro Butterworth*: Tipologia di filtro nota per avere una risposta in ampiezza massimamente piatta nella banda passante (nessuna oscillazione o distorsione del guadagno nelle frequenze utili).
- *Fase Zero (sosfiltfilt)*: Applicazione bidirezionale per evitare sfasamenti tra derivazioni periferiche.

3. Decimazione Polifase e Anti-Aliasing (Downsampling a 250 Hz):

- *Frequenza di Nyquist ($f_N = 125$ Hz)*: Frequenza massima correttamente campionabile ad una frequenza di target di 250 Hz ($250/2 = 125$ Hz). Qualsiasi frequenza superiore a 125 Hz presente nel segnale originale provocherebbe il fenomeno dell'*aliasing* (distorsione spettrale per cui segnali ad alta frequenza si ripiegano e appaiono falsamente come segnali a bassa frequenza).
- *Doppia Barriera Anti-Aliasing*:
 1. Il filtro Butterworth limita la banda passante a 120 Hz, attenuando l'energia spettrale prima del limite di Nyquist (125 Hz).
 2. La funzione `scipy.signal.resample_poly` progetta ed applica un filtro digitale **FIR (Finite Impulse Response - Risposta all'impulso finita) passa-basso ideale a finestra di Kaiser** con frequenza di taglio impostata rigidamente a 125 Hz prima di eseguire la decimazione polifase, eliminando matematicamente ogni residuo di aliasing.

Snippet Software del Preprocessing (data_pipeline.py):

```
def bandpass_filter(signal_data, fs=FS_OLD, lowcut=0.5, highcut=120.0, order=4):
    """Applica un filtro Butterworth passa-banda SOS (fase zero)."""
    sos = signal.butter(order, [lowcut, highcut], btype='bandpass', fs=fs,
output='sos')
    return signal.sosfiltfilt(sos, signal_data)

def leads_preprocessing(signal_data):
    """Pipeline di preprocessing standardizzata su singola derivazione ECG."""
    # 1. Filtro Notch 50 Hz (Q=30)
    b, a = signal.iirnotch(50.0, 30.0, fs=FS_OLD)
    y_notch = signal.filtfilt(b, a, signal_data)

    # 2. Filtro Passa-Banda 0.5-120 Hz (SOS)
    y_band = bandpass_filter(y_notch, fs=FS_OLD)

    # 3. Decimazione polifase a 250 Hz (FIR Kaiser)
    y_resampled = signal.resample_poly(y_band, up=FS_NEW, down=FS_OLD)
    return y_resampled.astype(np.float32)
```

Validazione Sperimentale (test_preprocessing.py):

- *Risposta in Frequenza (Test 1)*: Guadagno a 0.1 Hz pari a -47.51 dB (rimozione deriva lenta); banda fisiologica ECG (1.0 Hz, 10.0 Hz, 50.0 Hz) preservata a ≈ 0.0 dB.

- *Attenuazione Notch (Test 2)*: Abbattimento spettrale del disturbo di rete a 50 Hz pari a **−45.74 dB** (rispetto a un limite minimo clinico di **−20 dB**).
- *PSD Welch (Power Spectral Density - Welch's Method) (Test 5)*: Algoritmo per stimare lo spettro di potenza del segnale dividendo il tracciato in finestre sovrapposte calcolando la trasformata di Fourier. L'analisi spettrale dimostra che la banda di energia del complesso QRS ($[5.0, 40.0]$ Hz) subisce una **perdita di potenza inferiore a 3.0 dB (Decibel - scala logaritmica)**, ovvero < 0.1 dB, corrispondente a una conservazione morfologica superiore al 99%. Ciò prova matematicamente che il condizionamento non danneggia né distorce la struttura diagnostica del battito.

2.3 Signal Quality Assessment (SQA) Clinica e Strutturale

Il modulo SQA opera a livello globale (check_ecg_quality) e di singola finestra da 2s (check_window_quality) per soddisfare i criteri qualitativi stabiliti dai cardiologi:

I 5 Criteri Clinici Soddisfatti:

1. *Rumore ad alta frequenza (>300 Hz)*: Totalmente bloccato a monte dal filtro passa-basso Butterworth a 120 Hz.
2. *Baseline Wandering (Deriva della Linea di Base) e Saturazioni*:
 - Deriva lenta (movimenti respiratori): Scartata se l'offset medio della linea di base supera la costante baseline_max_uv ($\$600, \mu V$ - microvolt, ovvero 0.6 mV, allineato al limite clinico standard di 0.5 mV).
 - Saturazione ADC (Analog-to-Digital Converter): Fenomeno in cui l'ampiezza fisica dell'ECG supera i limiti hardware del convertitore dell'elettrocardiografo. Rilevato dal check *Clipping* (soglia di ampiezza a $\$6000, \mu V$ su una quota superiore al 2% dei campioni).
 - Reset hardware repentini: Identificati dal check *ADC Step* (derivata temporale istantanea $\$ > 2000, \mu V$).
3. *Presenza del Battito Fisiologico (check_physiological_ecg)*:
 - Metodologia: Calcola la derivata prima discreta $|\Delta w| = |w_i - w_{i-1}|$ su una finestra da 2s per rilevare variazioni rapide tipiche del QRS.
 - Soglia adattativa: $\text{threshold} = \max(\text{mean_diff} \cdot 4, 5.0 \mu V)$, dove mean_diff è la differenza assoluta media locale, permettendo al detector di auto-tararsi su diversi rapporti segnale-rumore.
 - Criterio di accettazione: Conteggio di picchi QRS coerente con un battito fisiologico compreso tra 1 e 6 battiti in 2s (corrispondenti a una **Frequenza Cardiaca di 30-180 bpm** - battiti al minuto), distanziati da un **intervallo refrattario** minimo di 0.3 secondi per evitare doppi conteggi, e con ampiezza picco-picco globale superiore a $\$50, \mu V$ (soglia minima per rilevare attività elettrica biologica).
4. *Durata Minima del Tracciato*:
 - L'esame ECG da 10 secondi viene convalidato globalmente se la percentuale di finestre da 2s approvate supera min_valid_ratio (0.60 per l'addestramento, 0.30 sui dati clinici reali), garantendo una continuità diagnostica minima di almeno 6 secondi.
5. *Inversioni Strutturali con Elettrodo di Terra RL (RL-RA / RL-LA)*:
 - Effetto fisico: L'elettrodo posizionato sulla gamba destra (RL - Right Leg) funge da *ground (terra) neutro* dell'elettrocardiografo e non registra potenziali elettrici di origine cardiaca. Uno scambio accidentale di RL con il braccio destro (RA) o sinistro (LA) rende patologicamente piatte ed esenti da morfologia le derivazioni periferiche II o III.

- Rilevamento finestra: Mediana assoluta μ_V (low_amplitude) e deviazione robusta della derivata < 1.5 (no_morphology).
- Rilevamento globale Einthoven: Controllo integrato basato sulle *leggi fisiche vettoriali di Einthoven-Burger-Wilson* ($I + III = II$). Se l'ampiezza picco-picco (ptp) o lo scostamento quadratico medio (std) della Lead II (per RL-RA) o della Lead III (per RL-LA) risulta ridotta di oltre il 60% rispetto alle derivazioni periferiche adiacenti, l'ECG intero viene rigettato per anomalia strutturale di terra.

Snippet: Rilevatore Morfologico QRS (check_physiological_ecg):

```
def check_physiological_ecg(window, fs=FS_NEW, min_qrs_amplitude=50.0):
    """Rilevatore euristico di eventi QRS su finestra da 2 secondi."""
    x = np.asarray(window, dtype=np.float64).squeeze()
    if len(x) < 3 or np.any(~np.isfinite(x)): return False, 0
    diff_x = np.abs(np.diff(x))
    mean_diff = np.mean(diff_x)
    if mean_diff == 0: return False, 0

    threshold = max(mean_diff * 4, min_qrs_amplitude / 10)
    peaks = np.where(diff_x > threshold)[0]
    if len(peaks) == 0: return False, 0

    actual_peaks = 1
    for i in range(1, len(peaks)):
        if peaks[i] - peaks[i - 1] > (fs * 0.3): actual_peaks += 1

    if 1 <= actual_peaks <= 6 and np.ptp(x) > min_qrs_amplitude:
        return True, actual_peaks
    return False, 0
```

Snippet: Controlli Fisici Strutturali Einthoven per Elettrodo di Terra (RL):

```
III
    # Rilevamento RL-RA: La Lead II è patologicamente piatta rispetto a I e
    is_II_flat = (ptp_II < 600 or std_II < 50.0)
    is_II_smaller_ptp = (ptp_II < ptp_I * 0.6) and (ptp_II < ptp_III * 0.6)
    if is_II_flat or is_II_smaller_ptp:
        valid_ecg = False
        reason = "structural_RL_RA"

    # Rilevamento RL-LA: La Lead III è patologicamente piatta rispetto a I e
    II
    is_III_flat = (ptp_III < 600 or std_III < 50.0)
    is_III_smaller_ptp = (ptp_III < ptp_I * 0.6) and (ptp_III < ptp_II * 0.6)
    if valid_ecg and (is_III_flat or is_III_smaller_ptp):
        valid_ecg = False
        reason = "structural_RL_LA"
```

Livello globale (check_ecg_quality):

Una derivazione globale x viene considerata anomala e rigettata se rispetta una delle seguenti condizioni fisiche:

- *Flatline*: $\sigma(x) < 25 \mu V \wedge PTP(x) < 40 \mu V$ (dove σ è la deviazione standard del segnale e PTP è l'ampiezza picco-picco).
- *Bassa ampiezza (Low amplitude)*: $\text{median}(|x|) < 14 \mu V$ (potenziale centrale patologicamente basso).
- *Assenza di morfologia (No morphology)*: $MAD(\Delta x) < 1.5$. La costante **MAD (Median Absolute Deviation - Deviazione Mediana Assoluta)** rappresenta una misura di dispersione spettrale robusta definita come:

$$MAD(y) = 1.4826 \cdot \text{median}(|y_i - \text{median}(y)|)$$

In questo caso viene applicata sulla derivata prima Δx per quantificare il rumore ad alta frequenza escludendo singoli outlier estremi.

- *Clipping*: Quota di campioni saturi ad $A_{\text{max}} = 6000 \mu V$ superiore al 2% del totale.

Livello finestra (check_window_quality - Finestra \$W = 2\\$s):

Check	Formula / Condizione	Soglia (default)	Scopo
Flatline	$\sigma(w) < 25 \wedge PTP(w) < 40$	$25 \mu V, 40 \mu V$	Rileva derivazioni spente o scollegate
Baseline wander	$ \bar{w} > \tau_b$	$\tau_b = 600 \mu V$	Rileva forti derive della linea di base dovute alla respirazione
ADC step	$\max(\Delta w) > 2000$	$2000 \mu V$	Rileva gradini impulsivi da ricalibrazione dell'ADC o ringing
Low energy	$\sigma(w) < \tau_e$	Arti: 15, Prec: $25 \mu V$	Rileva assenza di complessi ventricolari QRS
Noise	$MAD(\Delta w) > \tau_n$	Arti: 25, Prec: $35 \mu V$	Rileva rumore EMG (muscolare) o interferenza ad alta frequenza
Low amplitude	$\text{median}(w) < 14$	$14 \mu V$	Rileva l'appiattimento fisiologico tipico degli scambi con RL
No morphology	$MAD(\Delta w) < 1.5$	1.5	Rileva l'assenza di variazioni strutturate (derivazione morta)
No heartbeat	Rilevatore QRS < 1 battito	—	Rileva l'assenza di complessi cardiaci in 2s (FC < 30 bpm)

Configurazioni SQA differenziate:

I parametri e le soglie tollerate vengono configurati in tre profili distinti a seconda del dataset di destinazione:

- **QUALITY_CFG**: Profilo standard rigido, utilizzato per scartare a priori tracciati rumorosi in fase di addestramento sintetico puro.
- **CFG_SYNTH_RELAXED**: Profilo intermedio con tolleranze di rumore ampliate, utilizzato per permettere una varianza controllata nei dataset di sviluppo.
- **CFG_REAL**: Profilo clinico reale. Disabilita i check di baseline drift e rumore muscolare ad alta frequenza ($\tau = \infty$) per prevenire scarti spuri dovuti a tremori reali dei pazienti in corsia, mantenendo rigorosamente attivi i soli controlli fisici strutturali (Flatline, RL ground swap e gradini di reset ADC).

Parametro	QUALITY_CFG (default)	CFG_SYNTH_RELAXED	CFG_REAL	Spiegazione
baseline_max_uv	600	1500	∞ (disabilitato)	Massima deriva baseline consentita in microvolt (μV)
mad_noise_limb	25	100	∞ (disabilitato)	Soglia rumore MAD consentito sulle derivazioni degli arti
mad_noise_prec	35	120	∞ (disabilitato)	Soglia rumore MAD consentito sulle derivazioni precordiali
std_low_limb	15	5	0.1	Deviazione standard minima del segnale per le derivazioni degli arti
std_low_prec	25	8	0.1	Deviazione standard minima per le derivazioni precordiali
min_mad_diff_limb	1.5	1.5	0.3	Soglia minima di variazione robusta per considerare il tracciato vivo
min_valid_ratio	0.60	0.40	0.30	Frazione minima di finestre da 2s valide richieste per convalidare l'ECG
Flatline/RL check	✔ Attivo	✔ Attivo	✔ Attivo	Abilitazione dei controlli fisici di Einthoven e di piattezza RL

- **Validazione dei Test** (*test_sqa_flags.py* e *test_sqa.py*): 15/15 PASS. Garantisce l'intercettazione del **100%** degli scambi fisici di terra strutturali (classi 6/7) azzerando i falsi rifiuti su tracciati reali rumorosi sotto il profilo QUALITY_CFG_REAL (profilo clinico).

2.4 Apprendimento delle Soglie SQA dal Modello

- *Limite delle soglie statiche*: La forte variabilità fisiologica rende impossibile definire confini rigidi manuali efficaci a priori su tutti i pazienti.
- *Strategia implementata*: Le soglie ottimali di qualità vengono **apprese implicitamente dal classificatore** durante l'addestramento, correlando i pattern di rumore direttamente alle decisioni dei medici (reported vs rejected), allineandosi in automatico allo standard clinico reale di refertabilità.

2.5 Normalizzazione Robust Z-Score e Conservazione dell'Ampiezza

La normalizzazione canale per canale (z-score indipendente applicato derivazione per derivazione) è errata in cardiologia poichè *appiattisce i rapporti di ampiezza reciproci* tra canali, distruggendo le informazioni diagnostiche relative all'asse elettrico del cuore e al calcolo dei vettori cardiaci (es. se la derivazione II ha ampiezza fisiologica doppia rispetto alla derivata I, normalizzandole singolarmente a deviazione standard pari a 1 si azzerà la loro proporzione relativa).

Algoritmo di Normalizzazione Globale Robust Z-Score:

1. Rimuove la mediana temporale di ciascun canale per eliminare gli offset DC (componente continua di tensione a valore costante) individuali.
2. Calcola l'IQR (*Interquartile Range - Intervallo Interquartile*) globale accumulando i campioni temporali di tutte e 6 le derivazioni periferiche degli arti (reference leads LIMB: I, II, III, aVR, aVL, aVF). L'IQR è la differenza tra il 75° percentile e il 25° percentile della distribution dei dati ed esprime la dispersione del 50% centrale del tracciato, rendendolo insensibile a picchi estremi di rumore (outlier).
3. Calcola il fattore di scala condiviso robusto dividendo l'IQR globale per il *fattore costante* 1.34896:

$$\text{scale_global} = \frac{\text{IQR}_{\text{global}}}{1.34896}$$

- *Significato del coefficiente 1.34896*: In una distribuzione gaussiana (normale) teorica pura, lo scarto interquartile IQR equivale esattamente a $1.34896 \cdot \sigma$ (dove σ è la deviazione standard). Dividendo l'IQR per questo valore fisso, si ricava una stima robusta e non distorta della deviazione standard complessiva dell'esame, escludendo gli artefatti isolati.
4. Divide ciascuna derivazione periferica per scale_global, *preservando matematicamente inalterate le differenze e i rapporti di ampiezza relativi* tra le derivazioni.

Snippet Software della Normalizzazione (config.py):

```
def robust_scale_ecg(sigs_array, eps=1e-8, reference_leads=None):
    """Normalizzazione globale robusta per preservare le ampiezze relative."""
    x = sigs_array.astype(np.float32)
    medians = np.median(x, axis=1, keepdims=True)
    ref = x[reference_leads, :] if reference_leads is not None else x
    q75, q25 = np.percentile(ref, [75, 25])
    iqr_global = q75 - q25
    scale_global = max(iqr_global / 1.34896, eps) # eps previene la divisione per
    zero
    x_norm = (x - medians) / scale_global
    if reference_leads is not None:
```

```

return x_norm, medians.squeeze(), scale_global
return x_norm

```

- *Validazione (test_domain_gap_extended.py / TestNormalizzazioneStabilita)*: Lo z-score robusto globale mantiene i valori normalizzati stabilmente confinati nel range $[-50, 50]$ anche in presenza di forti anomalie transitorie, prevenendo lo shortcut bias ed evitando sovraeccitazioni dei pesi del modello.

2.6 Generazione dei Dataset HDF5 e Rimozione dell'Augmentation stocastica

La pipeline di generazione (build_unlabelled_global_zscore_dataset.py) crea i dataset finali salvati in formato *HDF5* (*Hierarchical Data Format v5 - un formato standardizzato internazionale per grandi moli di dati scientifici*) tramite calcolo parallelo multiprocesso:

Per ciascun tracciato ECG sorgente:

1. Caricamento file EDF e verifica SQA globale.
2. Per classe 0 (normale): Preprocessing → Normalizzazione → Finestratura.
3. Per classi 1-5 (inversioni periferiche): Calcolo della combinazione lineare esatta basata sui principi di Einthoven → Preprocessing → Normalizzazione → Finestratura.
4. Filtraggio a finestra tramite SQA.
5. Salvataggio HDF5 con compressione *LZF* (algoritmo di compressione lossless/senza perdita, estremamente veloce ad impatto computazionale minimo) e shuffle a blocchi casuali.

Struttura dei dataset generati:

Dataset	Ruolo	Augmentation	ECG sorgente impiegati
_train.h5	Addestramento	✗ No (Rumore fisiologico reale)	80% degli ECG normali del database
_val.h5	Validazione (sintetico)	✗ No	10% degli ECG normali del database
_test.h5	Test (sintetico)	✗ No	10% degli ECG normali del database

- *Rimozione dell'Augmentation Rumore e Shortcut Learning*: Nelle prime versioni della pipeline veniva applicata una data augmentation che iniettava rumore stocastico artificiale (rumore bianco gaussiano a livello di elettrodo, deriva sinusoidale artificiale per la respirazione e spike EMG artificiali). Tuttavia, le analisi di domain gap estese hanno rivelato che l'aggiunta di rumore sintetico induceva uno **shortcut learning critico** (il modello tendeva ad apprendere scorciatoie statistiche semplici basate sulle firme frequenziali artificiali del rumore simulato associate a classi specifiche, anziché studiare la morfologia dei complessi cardiaci). Ciò provocava un drastico decadimento delle performance cliniche reali (gap sim-to-real). Dato che gli ECG sani estratti dal database clinico contengono già inalterati il rumore di contatto, i tremori muscolari naturali ed il drift respiratorio originale di acquisizione, la simulazione lineare esatta delle inversioni periferiche preserva integralmente questo pattern reale inalterato. Di conseguenza, l'augmentation stocastica artificiale è stata rimossa, portando a zero il gap sim-to-real e incrementando sensibilmente l'accuratezza di generalizzazione.

2.7 Augmentation e Targeted Noise

Le tecniche di augmentation utilizzate per la generazione dei dataset correnti (`unlabelled_targeted_noise_limbs_train.h5` e affini) sono state raffinate, mantenendo solo trasformazioni validate per colmare il *Sim-to-Real Gap* senza alterare la struttura morfologica di base:

1. **Electrode Gain Universale:** Applicato a tutti gli ECG (inclusa la classe Normale) *prima* del preprocessing. Consiste in un rumore fisiologico di base moltiplicato per $1.1x$, calibrato in modo da pareggiare i livelli di rumore naturale medi tra il dataset sorgente originario e i dispositivi di registrazione ospedalieri usati nel test set.
2. **Targeted Extra Noise (Rumore Mirato per Classe):** Rumore muscolare addizionale aggiunto *solo* alle classi invertite, calibrato mediante Test di Kolmogorov-Smirnov (KS) sulle distribuzioni cliniche reali:
 - **ROT_ANTIORARIA:** Moltiplicatore di rumore moderato, campionato uniformemente in $[1.0, 2.5]$.
 - **ROT_ORARIA:** Moltiplicatore lievemente superiore, in $[1.2, 3.0]$.
 - **RA-LL e LA-LL:** Rumore **bimodale**. Poiché nei dati reali queste inversioni presentano una varianza estrema (o molto pulite o altamente rumorose a causa degli elettrodi posizionati sulle gambe), il rumore viene scisso a probabilità 0.5:
 - *Fascia bassa:* $[1.0, 1.5]$
 - *Fascia alta:* $[2.0, 4.0]$

Entrambe le tecniche operano sui segnali RAW originari e rispettano le **Equazioni di Einthoven**, garantendo l'integrità del vincolo spaziale $II = I + III$ e impedendo al classificatore di usare il rumore stesso come *shortcut* per dedurre l'inversione.

3. Architetture dei Modelli

Per gestire la diversa natura spaziale e informativa delle derivazioni periferiche rispetto a quelle precordiali, sono state sviluppate due architetture dedicate.

3.1 LDenseNet (Lightweight DenseNet per Derivazioni Periferiche)

Il modello è basato sull'architettura DenseNet, adattata per segnali 1D:

Input: (500, 6) – 2 secondi × 6 derivazioni periferiche

Stem Block:

Conv1D(16 filtri, kernel=11, stride=2) → Swish → MaxPool1D(3, stride=2)

Dense Block (3 layer):

Per ogni layer:

Bottleneck: Conv1D(32 filtri, kernel=1) → Swish

Conv1D(8 filtri, kernel=7) → Swish

Concatenazione con input (connessione densa)

Global Average Pooling 1D

Dropout(0.5)

```
Dense(6, softmax)
```

```
Output: 6 probabilità (una per classe)
```

Parametri totali: ~15K (modello estremamente leggero, adatto all'esecuzione in tempo reale su dispositivi edge/holter).

3.2 Modello ILC (Independent Lead Convolution) per Derivazioni Precordiali

Per rilevare gli scambi complessi tra le derivazioni toraciche (V1-V6), è stata implementata un'architettura specialistica denominata **ILC (Independent Lead Convolution con Cross-Channel Correlation)**. A differenza delle derivazioni periferiche (vincolate geometricamente da Einthoven), le precordiali richiedono l'analisi dell'evoluzione morfologica spaziale progressiva dell'onda R lungo il torace.

Principio di Funzionamento:

1. **Branch Convolution Indipendente:** Ogni singola derivazione precordiale viene elaborata parallelamente e in modo indipendente attraverso lo stesso blocco estrattore di feature condiviso (una variante LDenseNet *single-lead*). Questo costringe la rete a estrarre la morfologia intrinseca della singola derivazione (es. la larghezza del QRS o l'ampiezza dell'onda T) senza mescolarla linearmente con le altre.
2. **Cross-Channel Correlation (CoF):** Le mappe di feature intermedie estratte da ogni ramo (a tre diversi livelli di profondità convoluzionale) vengono confrontate a coppie tramite **Coseno-Similitudine**. Questo modulo esplicita matematicamente la correlazione spaziale incrociata tra gli elettrodi (es. verifica la coerenza evolutiva tra V3 e V2).
3. **Fusione Globale:** Le feature morfologiche indipendenti (su cui viene applicato un Global Average Pooling) e i coefficienti di correlazione spaziale estratti vengono fusi e passati a uno strato denso finale per la classificazione sulle 16 classi (1 normale + 15 anomalie precordiali).

```
Input: (500, 6) – 2 secondi × 6 derivazioni precordiali
```

```
Branch Model (ripetuto parallelamente 6 volte, 1 per ogni canale):
```

```
Input singolo canale: (500, 1)
```

```
Stem Block:
```

```
Conv1D(16 filtri, kernel=7, stride=2) → Swish → MaxPool1D(3, stride=2)
```

```
Dense Block (3 layer):
```

```
Per ogni layer:
```

```
Bottleneck: Conv1D(32 filtri, kernel=1) → Swish
```

```
Conv1D(8 filtri, kernel=7) → Swish
```

```
Concatenazione con input (connessione densa)
```

```
Output Branch: 3 mappe di feature intermedie + mappa di feature finale
```

```
Cross-Channel Correlation (CoF):
```

```
Calcolo Coseno-Similitudine tra tutte le coppie di derivazioni (15 combinazioni per 6 canali)
```

```
Calcolo ripetuto su 3 livelli di profondità convoluzionale (15 × 3 = 45 coefficienti totali)
```

```
Fusione (Fusion Layer):
```

```
Global Average Pooling 1D sulle 6 mappe di feature finali  
Concatenazione: [Feature morfologiche poolate] + [45 coefficienti di  
correlazione CoF]
```

```
Classificatore:  
Dense(64, ReLU)  
Dense(16, Softmax)
```

```
Output: 16 probabilità (1 classe normale + 15 classi di anomalie)
```

4. Training

4.1 Pre-addestramento su Dati Sintetici

Il modello viene addestrato da zero sul dataset sintetico:

Parametro	Valore
Ottimizzatore	Adam
Learning Rate	10^{-3}
Batch Size	256
Epoche	50 (con early stopping)
Loss	Categorical Cross-Entropy
Metrica checkpoint	F1-macro sulla validazione
Early Stopping	Patience 4 sul val F1-macro
LR Scheduler	ReduceLROnPlateau (factor 0.5, patience 5)

Il training utilizza un generatore HDF5 ([H5DataGenerator](#)) che legge i dati sequenzialmente dal file già shufflato su disco, evitando di caricare l'intero dataset in RAM.

4.2 Fine-Tuning Mirato con Class Weights (resume_train_limbs.py)

Sebbene il modello addestrato sui dati sintetici dimostri eccellenti capacità di generalizzazione, per colmare le residue confusioni asimmetriche (in particolare verso la classe [ROT_ANT](#) e [RA-LL](#)) è stata implementata una fase di **fine-tuning controllata**.

A differenza del training tradizionale su dati reali etichettati (che causerebbe rapido overfitting data la scarsità dei campioni ospedalieri bilanciati), il fine-tuning viene condotto **sul medesimo dataset sintetico aumentato**, ma con una configurazione iper-parametrica progettata per forzare il classificatore a risolvere le ambiguità:

Protocollo di Fine-Tuning:

1. **Partial Unfreezing (Sblocco parziale)**: Viene scongelato solo il classificatore denso finale. I layer convoluzionali precedenti, che hanno già appreso ad estrarre correttamente la morfologia di base del

- complesso QRS, vengono mantenuti congelati per non distruggere le feature robuste già acquisite.
2. **Learning Rate Ultra-Basso:** Il learning rate (LR) viene abbassato a 10^{-5} (un centesimo rispetto al training originale) e mantenuto costante per un limite ridotto di **10 epoche** (con Early Stopping). Questo garantisce un aggiustamento micrometrico dei confini decisionali senza sbalzi violenti dei pesi.
3. **Pesi Asimmetrici (Class Weights):** Per compensare in modo mirato le confusioni specifiche osservate in fase di test, vengono applicate penalità asimmetriche alla Loss (Categorical Cross-Entropy). Il modello è forzato matematicamente a prestare maggiore "attenzione" alle inversioni più difficili da distinguere:
- *Classe 0 (Normale):* 1.0
 - *Classe 1 (LA-RA):* 1.0
 - *Classe 2 (RA-LL):* 1.5
 - *Classe 3 (LA-LL):* 1.0
 - *Classe 4 (ROT_ORA):* 1.5
 - *Classe 5 (ROT_ANT):* 1.8 (Penalità massima)

L'intersezione tra pesi asimmetrici mirati e il decongelamento esclusivo del layer decisionale garantisce un riallineamento ottimale del Recall per le rotazioni critiche, prevenendo del tutto il decadimento delle prestazioni sulle classi "facili".

5. Risultati Sperimentali

5.1 Performance del Modello Baseline (Solo Sintetici → Test Reali)

Il modello addestrato esclusivamente su dati sintetici viene valutato sul test set reale (1090 finestre bilanciate):

Classe	Precision	Recall	F1	Support
Normale	0.93	0.99	0.96	545
LA-RA	0.57	0.99	0.72	109
RA-LL	0.97	0.83	0.89	109
LA-LL	0.95	0.64	0.77	109
ROT_ORA	1.00	0.99	1.00	109
ROT_ANT	0.98	0.41	0.58	109
Media (Macro)	0.90	0.81	0.82	1090

Metriche globali:

- **Accuratezza Totale:** 88.26%
- **AUROC (Macro):** 0.9903
- **AuPRC (Macro):** 0.9434

Analisi degli errori:

- La classe **ROT_ANT** mostra ancora il recall più basso (41%), seppur in miglioramento, segnalando che il modello baseline fa fatica sulle varianti complesse.

- La classe **LA-LL** ha un recall del 64%, mostrando ancora difficoltà nel distinguere i pattern da casi normali.
- **ROT_ORA** e **Normale** mantengono performance eccellenti (recall quasi al 100%).

5.2 Performance sui Dati Simulati

Lo stesso modello baseline valutato sul test set sintetico (73.542 finestre, 12.257/classe):


Classe	Precision	Recall	F1	Support
Normale	0.95	0.96	0.95	12257
LA-RA	0.95	0.96	0.95	12257
RA-LL	0.96	0.92	0.94	12257
LA-LL	0.95	0.95	0.95	12257
ROT_ORA	0.93	0.97	0.95	12257
ROT_ANT	0.96	0.94	0.95	12257
Media (Macro)	0.95	0.95	0.95	73542

Metriche globali:

- **Accuratezza Totale:** 95.07%
- **AUROC (Macro):** 0.9956
- **AuPRC (Macro):** 0.9837

Analisi degli Errori:

- **Normale** (n=12257): TP=11712 | confuso con → LA-LL=409, LA-RA=46, RA-LL=46, ROT_ORA=27, ROT_ANT=17
- **LA-RA** (n=12257): TP=11784 | confuso con → ROT_ANT=324, ROT_ORA=84, RA-LL=41, normale=21, LA-LL=3
- **RA-LL** (n=12257): TP=11333 | confuso con → ROT_ORA=761, normale=83, ROT_ANT=39, LA-LL=33, LA-RA=8
- **LA-LL** (n=12257): TP=11661 | confuso con → normale=450, ROT_ANT=54, ROT_ORA=45, LA-RA=39, RA-LL=8
- **ROT_ORA** (n=12257): TP=11879 | confuso con → RA-LL=303, LA-RA=31, LA-LL=27, ROT_ANT=15, normale=2
- **ROT_ANT** (n=12257): TP=11551 | confuso con → LA-RA=529, LA-LL=93, RA-LL=51, normale=22, ROT_ORA=11



5.3 Performance del Modello Fine-Tuned

Per colmare ulteriormente le confusioni residue sulle classi più complesse (in particolare **ROT_ANT** e **RA-LL**), il modello è stato sottoposto a una fase di fine-tuning controllata (`resume_train_limbs.py`). In questa fase, sono stati sbloccati solo gli ultimi 3 layer (il classificatore denso finale) per garantire maggiore flessibilità senza distruggere le feature apprese in precedenza. L'addestramento è stato condotto con un learning rate ridotto (10^{-5}) e pesi differenziati per classe (`class_weights` maggiorati fino a 1.8x per **ROT_ANT** e 1.5x per **RA-LL** e **ROT_ORA**).

Di seguito i risultati sul test set reale (1090 finestre bilanciate) post fine-tuning:

Classe	Precision	Recall	F1	Support
Normale	0.96	1.00	0.98	545
LA-RA	0.60	0.97	0.74	109


Classe	Precision	Recall	F1	Support
RA-LL	0.97	0.76	0.85	109
LA-LL	0.99	0.82	0.89	109
ROT_ORA	1.00	0.97	0.99	109
ROT_ANT	0.96	0.59	0.73	109
Media (Macro)	0.91	0.85	0.86	1090

Metriche globali post Fine-Tuning:

- **Accuratezza Totale:** 91.01% (vs 88.26% della baseline pre-fine-tuning)
- **AUROC (Macro):** 0.9896
- **AuPRC (Macro):** 0.9414

Analisi degli Errori Residui:

- L'introduzione dei *class weights* ha innalzato il recall di **ROT_ANT** dal 41% al 59% e mantenuto quello di **RA-LL** a livelli ottimali (76%), riducendo l'ambiguità complessiva.
- Tuttavia, la classe **LA-RA** si dimostra un "attrattore" per le inversioni più complesse: assorbe infatti ben 45 errori provenienti da **ROT_ANT** e 26 errori provenienti da **RA-LL**. Questa sovrapposizione è giustificata dalle forti similarità morfologiche derivanti dalle alterazioni dell'asse cardiaco frontale.
- Il recall di **LA-LL** è salito notevolmente (dal 64% all'82%), sebbene il modello fatichi ancora leggermente su pattern ambigui, classificando 20 finestre invertite come tracciati normali.
- L'accuratezza complessiva è balzata al **91%**, dimostrando l'efficacia del parziale congelamento dei pesi abbinato alle penalità asimmetriche per le classi difficili.



5.4 Estensione alle Derivazioni Precordiali (Sim-to-Sim)

Il sistema è stato esteso per rilevare 15 classi di inversioni complesse tra le derivazioni toraciche (V1-V6). A causa della fisiologia progressiva del segnale precordiale, la validazione è stata condotta tramite la rete **ILC**. Di seguito i risultati del test set simulato (6591 finestre) per le 16 classi totali:


Metriche globali:

- **Accuratezza Totale:** 98.04%
- **AUROC (Macro):** 0.9989
- **AuPRC (Macro):** 0.9928

Classe	Precision	Recall	Specificity	F1-Score
Classe 0 (Normale)	0.9126	0.9404	0.9940	0.9263

Classe	Precision	Recall	Specificity	F1-Score
Classe 1	0.9736	0.9848	0.9982	0.9792
Classe 2	0.9933	0.9936	0.9995	0.9934
Classe 3	0.9961	0.9976	0.9997	0.9969
Classe 4	0.9960	0.9964	0.9997	0.9962
Classe 5	0.9988	0.9969	0.9999	0.9978
Classe 6	0.9644	0.9447	0.9977	0.9544
Classe 7	0.9943	0.9887	0.9996	0.9915
Classe 8	0.9827	0.9939	0.9988	0.9883
Classe 9	0.9966	0.9925	0.9998	0.9946
Classe 10	0.9838	0.9804	0.9989	0.9821
Classe 11	0.9783	0.9904	0.9985	0.9844
Classe 12	0.9963	0.9898	0.9998	0.9931
Classe 13	0.9734	0.9744	0.9982	0.9739
Classe 14	0.9827	0.9756	0.9989	0.9791
Classe 15	0.9656	0.9464	0.9978	0.9559

Il modello ILC dimostra una capacità eccezionale di estrarre le relazioni spaziali complesse sul torace, raggiungendo metriche F1 stabilmente superiori al **97%** su quasi tutte le 15 combinazioni di scambio precordiale, con punte del 99.7% nelle classi più evidenti. L'architettura a convoluzioni indipendenti compensa egregiamente l'assenza di relazioni di Einthoven tra le precordiali, mantenendo l'accuratezza totale al **98.04%** in fase di test intra-dominio (sintetico).



5.5 Approccio Self-Supervised (SSL - Domain Adaptation) con Pseudo-Labeling

Per valorizzare la scarsità di tracciati reali etichettati e sfruttare l'ampio pool di elettrocardiogrammi non etichettati presenti nel database ospedaliero, è stato implementato un paradigma di apprendimento basato su **Offline Pseudo-Labeling con Pre-training su Simulato (SSL - Domain Adaptation)** nel modulo `src/self_supervised`.

Questo approccio sfrutta il modello pre-addestrato sui dati sintetici (ottenuti tramite simulazione matematica delle inversioni). Il modello, altamente robusto e privo di sbilanciamenti, viene utilizzato in un singolo passaggio (offline) per etichettare un pool di ECG reali non etichettati, precedentemente selezionati filtrando i referti clinici tramite parole chiave inerenti a possibili scambi di elettrodi (`candidate_ids.json`). I tracciati pseudo-etichettati vengono integrati all'interno di un dataset H5 bilanciato per l'addestramento finale del modello. Questo approccio riduce il rischio di *confirmation bias* in quanto il modello di partenza possiede già un'ottima capacità di discriminazione spaziale delle inversioni, fungendo da guida robusta per la domain adaptation.


Risultati Sperimentali e Discussione

Il modello pre-addestrato su dati simulati (Originale) e il modello ri-addestrato con l'integrazione dei dati reali pseudo-etichettati (SSL) sono stati valutati sul test set simulato di grandi dimensioni composto da 73.542 finestre (12.257 per ciascuna delle 6 classi). Di seguito è riportata la tabella riassuntiva del confronto prestazionale:

Metrica	Modello Originale	Modello SSL	Delta
Accuratezza	95.07%	97.08%	+2.00%
AUROC (Macro)	0.9956	0.9969	+0.13%
AuPRC (Macro)	0.9837	0.9891	+0.54%

Matrici di Confusione a Confronto

Di seguito vengono riportate le matrici di confusione prima e dopo l'integrazione dei dati reali pseudo-etichettati tramite l'approccio self-supervised (SSL):



Dall'analisi comparativa emergono considerazioni cliniche e metodologiche di rilievo:

1. **Risoluzione delle ambiguità geometriche:** L'introduzione nel training set di tracciati reali pseudo-etichettati mediante *offline self-training* ha permesso alla rete di raffinare i confini decisionali. La confusione della classe di rotazione antioraria (ROT_ANT) con lo scambio LA-RA è scesa da 529 a 361 casi.
2. **Correzione di scambi asimmetrici complessi:** Il miglioramento più vistoso riguarda lo scambio RA-LL (rosso-verde), che nel modello originale veniva confuso ben 761 volte con la rotazione oraria (ROT_ORA). Nel modello SSL tale confusione crolla a soli 210 casi, indicando che l'esposizione alle naturali variazioni morfologiche dei segnali reali (anche se pseudo-etichettati) stabilizza l'apprendimento delle relazioni di Einthoven apprese teoricamente sui dati simulati.

3. **Consolidamento della classe Normale e LA-LL:** I falsi positivi della classe **LA-LL** (scambiati con segnali normali) si riducono da 450 a 372. L'accuratezza totale sale così al **97.08%**, confermando che l'integrazione mirata dei reali tramite SSL (Step 3) riduce il domain shift senza causare degrado prestazionale.
-

6. Analisi dei Risultati e Comparazione delle Configurazioni

6.1 Composizione e Razionale del Dataset di Training

Per addestrare modelli in grado di generalizzare efficacemente in scenari reali ("in-the-wild"), è stato necessario superare la sfida dei falsi positivi indotti da alterazioni morfologiche fisiologiche o patologiche del tracciato. A questo scopo, è stato costruito un dataset di addestramento specifico, estraendo 20.000 referti verificati dal database ospedaliero (**records_complete.db**).

Per garantire la pulizia del dato, sono stati scartati a priori tutti i referti contenenti keyword relative a malposizionamenti espliciti (es. "scambio", "errato", "periferic"), artefatti tecnici o presenza di pacemaker. Il dataset risultante è stato bilanciato per includere un numero uguale di campioni per categorie cliniche strategiche:

- **5.000 ECG Sani** (Tracciati normali, asse compreso tra -30° e $+90^\circ$)
- **5.000 ECG con Blocco di Branca Destra (RBBB)** (Variazioni dei vettori terminali del QRS verso destra)
- **5.000 ECG con Deviazioni Assiali:** suddivisi tra ~ 2.000 Deviazioni Assiali Destre (RAD, asse tra $+90^\circ$ e $+180^\circ$) e ~ 3.000 Sinistre (LAD, asse tra -30° e -90°)
- **5.000 ECG con Patologie Miste** (Altro)

L'importanza della distribuzione e della deviazione dell'asse: Questa scelta distributiva è il cuore della robustezza del modello. Le inversioni degli elettrodi periferici causano profonde alterazioni dell'asse elettrico sul piano frontale. Ad esempio, l'inversione LA-LL devia marcatamente l'asse verso sinistra (mimando una LAD tra -30° e -90°), mentre l'inversione RA-LL devia l'asse tipicamente verso destra (mimando una RAD tra $+90^\circ$ e $+180^\circ$). Forzando l'esposizione della rete neurale a patologie che presentano deviazioni assiali fisiologiche correlate all'inversione, il modello viene addestrato a percepire le sottili differenze morfologiche tra una vera deviazione asse patologica e una deviazione indotta dal malposizionamento degli elettrodi. Questo approccio abbassa drasticamente l'incidenza di falsi positivi su pazienti cardiopatici.

6.2 Esperimenti e Setup delle Derivazioni

Al fine di quantificare il reale apporto informativo di ciascun elettrodo, l'architettura è stata testata incrementando progressivamente la disponibilità spaziale delle derivazioni. Tutti i test successivi riportano le metriche calcolate aggregando le finestre a livello "per paziente", confrontando le predizioni con le annotazioni cliniche reali non-gold standard.

6.2.1 Setup **limbs_extended** (III, aVR, V6)

Il primo esperimento costituisce un test di "stress" dell'architettura. In questa configurazione, le derivazioni periferiche vengono tagliate drasticamente, fornendo alla rete in ingresso solamente tre tracce: **III, aVR e V6**. Nonostante l'apparente povertà del dato, le derivazioni III e aVR formano un sistema vettoriale indipendente e robusto sul piano frontale di Einthoven, fornendo le componenti matematiche di base da cui è possibile

estrarre l'asse. A questa base matematica viene fisicamente concatenato il segnale della derivazione **V6**. Questa aggiunta fornisce alla rete un'indispensabile "ancora" spaziale: provenendo dal piano orizzontale (precordiale), V6 non è quasi mai affetta dagli scambi degli arti e rappresenta il riferimento assoluto dell'apice sinistro del cuore. Questo permette al modello di dirimere le ambiguità speculari generate dalle sole periferiche. Pur osservando un leggero calo delle performance dovuto alla perdita di risoluzione, il modello mantiene una precisione sorprendente.

6.2.2 Setup **limbs_complete** (Tutte le Periferiche + V6)

Nel secondo step è stato reintrodotta l'intero set delle 6 derivazioni periferiche classiche (I, II, III, aVR, aVL, aVF) sempre affiancate dall'ancora V6. L'uso congiunto di tutte le derivazioni frontali annulla il fisiologico calo di performance dell'esperimento precedente. Il modello riacquista piena confidenza, "pulendo" la diagonale della matrice di confusione dai falsi positivi residui. Questo setup definisce il bilanciamento ideale ("sweet spot") tra affidabilità clinica e minimizzazione dell'input.

6.2.3 Setup **limbs_v1+v6**

Per verificare la possibilità di estrarre ulteriore margine prestazionale, all'esperimento **complete** è stata aggiunta la derivazione V1, fornendo al modello anche un'informazione diretta sull'elettrofisiologia del lato destro del cuore. I risultati dimostrano una chiara saturazione: l'aggiunta di V1 non produce alcun miglioramento significativo. Questo certifica definitivamente che la derivazione V6, per via della sua stabilità morfologica, è da sola un riferimento sufficiente e ottimale per la classificazione.

6.3 Confronto Visivo: Matrici di Confusione Per Paziente

Di seguito si riportano le tre matrici di confusione calcolate sui pazienti reali (Non-Gold) per le tre configurazioni testate.




Figura 1: Modello *Limbs_extended*. Nonostante le sole 3 derivazioni fornite, la base vettoriale permette ottimi risultati, seppur con un lieve accumulo di errori fisiologici e confusione tra famiglie.




Figura 2: Modello *Limbs_Complete*. Il ritorno al set completo assicura il recupero prestazionale pieno, migliorando la precisione sulla diagonale principale.




Figura 3: Modello *limbs_v1+v6*. La saturazione delle performance è evidente: la matrice è pressoché identica alla precedente, a riprova che V1 non aggiunge un guadagno informativo utile ai fini di questo task.

6.4 Analisi degli Errori e Confusione tra "Famiglie"

Analizzando le matrici di confusione (in particolar modo per il modello *extended* e in misura minore per i successivi), si nota che la rete neurale non sbaglia in modo casuale, ma tende a confondere sistematicamente inversioni appartenenti a specifiche "famiglie" elettrofisiologiche o posizionali che condividono forti somiglianze morfologiche:

1. **Confusione tra Normale e LA-LL:** L'inversione Braccio Sinistro - Gamba Sinistra (LA-LL) è l'errore tecnicamente più insidioso. Molto spesso, il segnale LA-LL produce modifiche al tracciato estremamente lievi che rientrano nelle varianti della normalità. È quindi l'inversione maggiormente predetta come "Normale".
2. **Confusione tra LA-RA e ROT_ANT (Rotazione Antioraria):** L'inversione tra le due braccia (LA-RA) condivide una profonda affinità con l'inversione fisica degli elettrodi precordiali (in questo caso, la simulazione o l'effetto di una rotazione antioraria). Entrambe queste condizioni invertono la direzionalità laterale dei vettori, portando la rete a confonderle frequentemente.

3. **Confusione tra ROT_ORA (Rotazione Oraria) e RA-LL:** Si osserva una spiccata tendenza della rete a scambiare la Rotazione Oraria con lo scambio Braccio Destro - Gamba Sinistra (RA-LL). Anche in questo caso, le complesse ripercussioni della RA-LL sull'asse (spostato verso l'alto e a destra) possono presentare tratti morfologici simili allo slittamento dei vettori generato da una rotazione oraria del cuore o degli elettrodi precordiali.

7. Validazione Clinica e Geometrica dell'AI: Il Teorema dell'Ambiguità

Questo capitolo dimostra matematicamente, visivamente e clinicamente perché le intelligenze artificiali superano l'accuratezza dei medici nel rilevare gli scambi degli elettrodi ECG, svelando un limite fisiologico della cardiologia visiva tradizionale.

7.1 Le Tre Famiglie: Equazioni e Incroci Esatti

Il colore delle derivazioni di Einthoven dipende solo dall'angolo θ dell'asse cardiaco:

$$I = \cos(\theta), \quad II = \cos(\theta - 60^\circ), \quad III = \cos(\theta - 120^\circ)$$

Due permutazioni diverse applicate a cuori con assi **diversi** possono produrre le stesse sei derivazioni periferiche. Questo è l'incrocio (o degenerazione).

Famiglia 2 — LA-RA vs Rotazione Antioraria dei Cavi

Le equazioni di trasformazione vettoriale sono:

$$\text{LA-RA:} \quad I' = -I, \quad II' = III, \quad III' = II$$

$$\text{ROT_ANT:} \quad I' = -II, \quad II' = -III, \quad III' = I$$


Imponendo $\text{LA-RA}(\alpha) = \text{ROT_ANT}(\beta)$ lead per lead e risolvendo il sistema, si ottiene la **relazione di incrocio**:

$$\beta = 60^\circ - \alpha$$


Cioè: il paziente con LA-RA e asse α_1 produce le stesse sei derivazioni periferiche del paziente con ROT_ANT e asse $\alpha_2 = 60^\circ - \alpha_1$. Per ogni α_1 esiste esattamente un α_2 corrispondente.

Famiglia 2: Identità Vettoriale tra LA-RA e Rotazione Antioraria

Paziente A (Asse 0°)
Errore Applicato: LA-RA




Paziente B (Asse 60°)
Errore Applicato: ROT_ANTIORARIA




Famiglia 2: Identità LA-RA/Rot.Antioraria su ECG Reale


Lead I




Lead II




Lead III




Lead aVR



Lead aVL



Lead aVF



Famiglia 3 — RA-LL vs Rotazione Oraria dei Cavi

$$\text{RA-LL: } I' = -III, \quad II' = -II, \quad III' = -I$$


$$\text{ROT_ORO: } I' = III, \quad II' = -I, \quad III' = -II$$

Risolvendo RA-LL(α) = ROT_ORO(β):


$$\beta = 60^\circ - \alpha \text{ (identica struttura di Famiglia 2)}$$

Famiglia 3: Identità Vettoriale tra RA-LL e Rotazione Oraria

Paziente A (Asse -30°)
Errore Applicato: RA-LL




Paziente B (Asse 90°)
Errore Applicato: ROT_ORARIA




Famiglia 3: Identità RA-LL/Rot.Oraria su ECG Reale


Lead I




Lead II




Lead III




Lead aVR



Lead aVL



Lead aVF



Famiglia 1 — Normale vs Scambio LA-LL


$$\text{LA-LL: } I' = II, \quad II' = I, \quad III' = -III$$

Risolvendo Normale(α) = LA-LL(β):


$$\beta = 60^\circ - \alpha \text{ (identica struttura)}$$

Famiglia 1: Identità Vettoriale tra Normale e LA-LL

Paziente A (Asse 45°)
Errore Applicato: Normal



Paziente B (Asse 15°)
Errore Applicato: LA-LL




Famiglia 1: Identità LA-LL su ECG Reale


Lead I




Lead II




Lead III




Lead aVR



Lead aVL



Lead aVF



Risultato unificato: tutte e tre le famiglie condividono la stessa struttura geometrica degli incroci. Due permutazioni diverse della medesima famiglia producono derivazioni periferiche identiche se e solo se i loro assi nativi soddisfano $\beta = 60^\circ - \alpha$, indipendentemente dalla famiglia considerata.

7.2 V6 e Global Z-Score: Risoluzione Analitica dell'Ambiguità

La derivazione V6, essendo toracica, non viene alterata dalla permutazione dei cavi periferici nella simulazione. V6 riflette quindi il cuore **nativo** del paziente e può essere usata per dedurre l'asse cardiaco reale.

Data la coppia di incrocio $(\alpha_1, \alpha_2 = 60^\circ - \alpha_1)$, V6 è approssimativamente:


$$V6(\alpha) \approx \cos(\alpha) \quad [\text{proiezione laterale sinistra}]$$

Se ci si basasse unicamente sul **segno** (positivo o negativo) dell'onda in V6, potremmo distinguere i due pazienti solo quando $\cos(\alpha_1)$ e $\cos(60^\circ - \alpha_1)$ hanno segno opposto. Questo accade solo in specifiche finestre assiali (che coprono circa il 33% degli incroci totali). Nei restanti casi (circa il 67%), i due assi nativi cadono entrambi in un range in cui V6 ha lo stesso segno per entrambi i pazienti, rendendoli visivamente ambigui per l'occhio umano.

Il Modulo e la Normalizzazione Relativa L'Intelligenza Artificiale risolve ogni singola ambiguità superando la semplice "polarità" visiva e analizzando analiticamente il **modulo (ampiezza)** del segnale. L'intero tracciato ECG viene riscalo tramite una normalizzazione **Robust Global Z-Score** applicata contemporaneamente a tutte le derivazioni.

Poiché le derivazioni periferiche generano una distribuzione di potenziale che varia fortemente con l'angolo α , il fattore di scala globale (basato sulla varianza totale dell'ECG) fluttuerà a seconda del vero asse nativo del paziente. Risultato: quando V6 (che è rimasta ancorata al cuore) viene divisa per questo fattore globale *influenzato dalle periferiche permutate*, la sua **ampiezza relativa** diventa un'impronta digitale univoca.

Anche nei casi in cui V6 ha lo stesso segno per entrambi i pazienti, la combinazione matematica del modulo di V6 con il Global Z-Score è sempre differente per α_1 e per $60^\circ - \alpha_1$. Considerando questa variazione di ampiezza, la Rete Neurale risolve il 100% degli incroci geometrici in modo deterministico.



7.3 Validazione Statistica sul Testset Clinico

Abbiamo sottoposto questa teoria alla prova del nove estraendo i veri assi elettrici dei pazienti dal testset ospedaliero reale. Abbiamo diviso le etichette in due grandi gruppi: i casi "Esemplari" in cui le regole umane funzionano, e i casi "Ambigui" (i Cigni Neri) in cui il medico soccombe all'illusione geometrica e l'AI lo deve correggere.

Famiglia 2 (LA-RA vs Rotazione Antioraria)

- **I Casi Esemplari (Il medico indovina, l'AI concorda): 184 pazienti**
 - **Asse Reale Medio:** $+38.1^\circ$ (Cuori sani e fisiologici)
 - **Analisi:** Se un paziente è geometricamente sano, la proiezione del LA-RA produce un tracciato inequivocabile. Il medico lo riconosce istantaneamente e con successo.
- **I Casi Ambigui (Il medico sbaglia, la Rete lo corregge): 34 pazienti**

- **Asse Reale Medio:** +2.1° (con picchi a -90° e -130°)
- *Analisi:* Come predetto dalla teoria! Questi pazienti hanno cuori patologici, pesantemente orizzontalizzati o deviati. In questo range, la Rotazione Antioraria imita alla perfezione il LA-RA classico. Il medico "scommette" statisticamente sulla classe più probabile (LA-RA) e sbaglia la diagnosi clinica.

Famiglia 1 (LA-LL vs Normale)

- **Casi Esemplari (Concordanti): 202 pazienti**
 - **Asse Reale Medio:** +46.6° (Cuori sani senza alterazioni evidenti).
- **Casi Ambigui (Il medico referta normale, la Rete trova lo scambio LA-LL): 11 pazienti**
 - **Asse Reale Medio:** +37.7° (Alta varianza)
 - *Analisi:* Lo scambio LA-LL mantiene le onde prevalentemente positive. Su questi 11 tracciati, l'errore infermieristico si è mimetizzato perfettamente in un "normale ritmo sinusale". L'occhio umano non ha colto il sottile scambio tra D1 e D2, mentre l'Intelligenza Artificiale ha letto la sproporzione tridimensionale con V6.

Famiglia 3 (RA-LL vs Rotazione Oraria)

- **Casi Esemplari (Concordanti): 15 pazienti**
 - **Asse Reale Medio:** +39.0° (Il tracciato risulta talmente distrutto da essere subito identificato dal medico).
- **Casi Ambigui (Il medico sbaglia, la Rete corregge in Rot_Oraria): 2 pazienti**
 - **Assi Reali:** +15.9° e +2.3°
 - *Analisi:* Ancora una volta, la deviazione orizzontale patologica dell'asse elettrico chiude la "trappola" geometrica, rendendo impossibile all'uomo differenziare il referto.

Conclusione: Il Referto Finale sull'Affidabilità

In sintesi, su un totale di **461 pazienti** analizzati nel testset clinico:

Esito Diagnostico	Conteggio	Percentuale	Descrizione Clinica
Casi Concordanti	401	87.0%	Il paziente ha un asse elettrico normale. L'errore genera un ECG inequivocabile e il medico lo riconosce a occhio nudo.
Sbaglia il Medico (Vince l'AI)	47	10.2%	I casi borderline. Il paziente ha un asse deviato che cade esattamente nelle equazioni dell'ambiguità. Il medico abbocca all'illusione 2D, l'AI risolve il caso in 3D con V6.
Sbaglia l'AI (Vince il Medico)	13	2.8%	L'AI fallisce (allucinazioni dovute a rumore estremo o tracciati anomali non visti in addestramento), mentre l'euristica umana regge.

Il motivo per cui il Medico indovina spontaneamente l'87% dei casi non è perché sa "distinguere" le classi delle famiglie, ma perché si affida all'euristica: statisticamente in ospedale gli errori come LA-RA sono

enormemente più frequenti delle Rotazioni. Il cardiologo "scommette" sul caso più probabile, accettando inesorabilmente un **10% di margine di errore strutturale** sui pazienti orizzontalizzati. L'Intelligenza Artificiale non scommette. Misurando la profondità z-score di V6, disinnesca l'inganno ottico in modo deterministico.

8. Suite di Test Automatizzati

Il progetto include una suite completa di test per garantire la correttezza della pipeline:

Test	File	Cosa verifica
Correttezza inversioni	<code>test_domain_gap_extended.py</code>	Formule matematiche, doppia inversione = identità
Assenza shortcut	<code>test_pipeline_v2.py</code>	Correlazione rumore tra classi < 0.3
Fisica Einthoven	<code>test_physics_domain.py</code>	$N_{III} = N_{II} - N_I$ per tutte le augmentation
Uniformità SNR	<code>test_pipeline_v2.py</code>	Range SNR tra classi $< 10\text{ dB}$
Domain gap statistico	<code>test_simulated_vs_real_anomalies.py</code>	KS test simulati vs reali
Preprocessing	<code>test_domain_gap_extended.py</code>	Determinismo, assenza NaN/Inf
SQA	<code>test_sqa_flags.py</code>	Corretto scarto classi RL-RA/RL-LA
Performance modello	<code>test_domain_gap.py</code>	Accuratezza, recall, calibrazione

9. Discussione e Limiti

Punti di forza

1. **Simulazione matematicamente corretta** e validata con test automatizzati
2. **Augmentation fisicamente coerente** (legge di Einthoven)
3. **Pipeline industriale**: parallelismo multi-processo, SQA a due livelli, configurazioni differenziate
4. **Eccellenti performance sui simulati** (97.65%) confermano che il modello ha appreso i pattern morfologici corretti
5. **AUROC 0.97 sui reali** indica un'ottima capacità discriminativa anche cross-dominio
6. **Fine-tuning efficace**: accuratezza da 86% a 92%, recall ROT_ANT da 21% a 86%

Limiti

1. **Sbilanciamento dei dati reali**: ROT_ORA ha solo 7 record (116 finestre), RA-LL ne ha 15 (319 finestre). L'oversampling e i class weights compensano parzialmente ma non possono sostituire la diversità dei dati reali.
2. **Confusione Normale → LA-LL**: la bassa precision di LA-LL (49%) indica che il modello genera falsi positivi significativi su questa classe. Il numero esiguo di record reali LA-LL (14) limita la capacità del modello di apprendere un confine decisionale preciso.

3. **Confusione LA-RA ↔ ROT_ANT**: queste due inversioni condividono componenti morfologiche simili (ROT_ANT include una permutazione ciclica che "contiene" una componente di LA-RA). La precision di ROT_ANT (62%) riflette questa ambiguità intrinseca.
4. **Varianza tra fold**: la deviazione standard del F1-macro (0.087) e soprattutto del recall RA-LL (0.393) indicano instabilità dovuta al numero esiguo di record per le classi minoritarie.

Lavori futuri

- **Raccolta dati**: priorità su RA-LL (15 record), LA-LL (14 record) e ROT_ORA (7 record). Anche 20-30 record aggiuntivi per classe migliorerebbero significativamente la stabilità
- **Tecniche di domain adaptation**: adversarial training o Maximum Mean Discrepancy (MMD) per ridurre il gap senza dati etichettati aggiuntivi
- **Estensione alle inversioni precordiali** (V1-V6), per cui il framework è già predisposto
- **Calibrazione del modello**: temperatura scaling per migliorare l'affidabilità delle probabilità predette

10. Struttura del Codice

```
src/
├── data/
│   ├── data_pipeline.py          # Preprocessing, SQA, inversioni, augmentation
│   └── generate_ids.py           # Estrazione ID ECG dal database
├── models/
│   └── ldensenet.py              # Architettura LDenseNet 1D
├── utils/
│   └── config.py                 # Configurazione globale (frequenze, classi,
SQA)
├──   └── sqa_real_config.py       # Configurazioni SQA differenziate
├── prove/
│   ├── build_unlabelled_global_zscore_dataset.py # Generazione dataset sintetici
│   ├── testset_validation.py      # Generazione test set reale bilanciato
│   ├── train_limbs.py             # Training su sintetici
│   ├── test_limbs.py              # Valutazione su reali e simulati
│   ├── kfold_finetune_limbs.py    # Fine-tuning 5-fold CV
│   └── tests/
│       ├── test_pipeline_v2.py     # Test shortcut e SNR
│       ├── test_physics_domain.py  # Test Einthoven
│       ├── test_domain_gap.py      # Test performance cross-dominio
│       ├── test_domain_gap_extended.py # Test correttezza matematica
│       ├── test_simulated_vs_real_anomalies.py # Test fedeltà simulazione
│       └── test_sqa_flags.py       # Test SQA
```